

Prueba técnica - Data Engineer

A continuación, adjuntamos [un fichero CSV](#) con los tickets de ventas de un cliente ficticio (transaccional de ventas).

Las columnas incluidas son:

- date: fecha de la venta
- hour: hora de la venta
- site_id: identificador de tienda
- site_name: Nombre de la tienda
- product_id: identificador de producto
- category1_id: identificador de la categoría a la que pertenece un producto
- total: cantidad total de euros de la transacción
- units: número de unidades

Los ejercicios a realizar durante la prueba serán los siguientes:

PARTE 1: PYTHON

1. Leer los datos en un Jupyter Notebook utilizando Python.
2. Obtén las dimensiones (Nº filas, Nº columnas)
3. Visualiza los posibles nulos
4. Elimina los posibles outliers del dataset (Variables: hour, units y total)
5. Elimina las filas en las que el site_id sea nulo
6. Imputa/rellena los valores nulos en el resto de las variables que tienen nulos.
7. Transforma la variable site_id a entero y guarda estos datos aparte para subirlos luego a SQL.
8. Genera una columna booleana que sea is_holidays, que representa un 1 cuando son vacaciones en España y 0 cuando no lo son. Comprueba que ha sido bien generado.
9. Generar secuencias temporales de ventas con el total de ventas por día para cada tienda y categoría, es decir, agrupando por fecha, site y categoría. Para cada una de las tiendas.
10. Realizar un plot de las secuencias temporales.

PARTE 2: SQL

1. Crea de una base de datos SQL llamada prueba_ladorian, vale en mysql o similar (local o Cloud).
2. Crea dentro una tabla llamada ventas.
3. Sube los datos tal y como los tenemos en el punto 7.
4. ¿Visualiza si existe alguna inconsistencia en sites entre id y name, es decir, existen ids con distintos nombres o nombres con distintos ids?

PARTE 3: CLOUD (consejo: usa draw.io para realizar el esquema)

1. Como automatizarías un proceso ETL que leyese un archivo, lo procesase y lo cargase en una base de datos utilizando los servicios Cloud de GCP. ¿Qué servicios utilizarías? **genera un esquema del proceso con los servicios que usarías.**
2. **API:** Una vez cargados los datos en Cloud, queremos cargar los datos en un servidor y montar una API para obtener analíticas sobre ellos. Qué servicios utilizarías para montar

la API en Cloud y que tecnologías utilizarías **genera un esquema del proceso con los servicios que usarías.**